AI CUP 2026 春季賽

ESG 永續承諾驗證競賽報告

隊伍資訊

隊伍：TEAM_10671

隊員：鄭兆宏（隊長）、王修佑、林德恩、韓欣劭

Private Leaderboard：0.6538186 / Rank 1

壹、環境

我們本競賽都使用 Linux 作業系統，以 Python 3.12 進行開發與訓練。硬體環境為單張 NVIDIA TITAN RTX（24 GB VRAM）、16 核心 CPU、62 GB 記憶體。且我們僅使用競賽官方提供之訓練、驗證、測試集，並未引入任何外部標註資料之資料集。

主要套件（函式庫）如下：

套件	版本	用途
PyTorch	2.12.0 (CUDA 12.6)	深度學習訓練框架
HuggingFace Transformers	≥ 4.30	載入與微調預訓練模型
scikit-learn	≥ 1.2	分層 K-fold 切分、Macro-F1 計算
NumPy	≥ 1.24	數值與資料處理
pandas	≥ 2.0	數值與資料處理
TensorBoard	≥ 2.14	訓練曲線記錄

預訓練模型（皆為 HuggingFace 公開權重）：

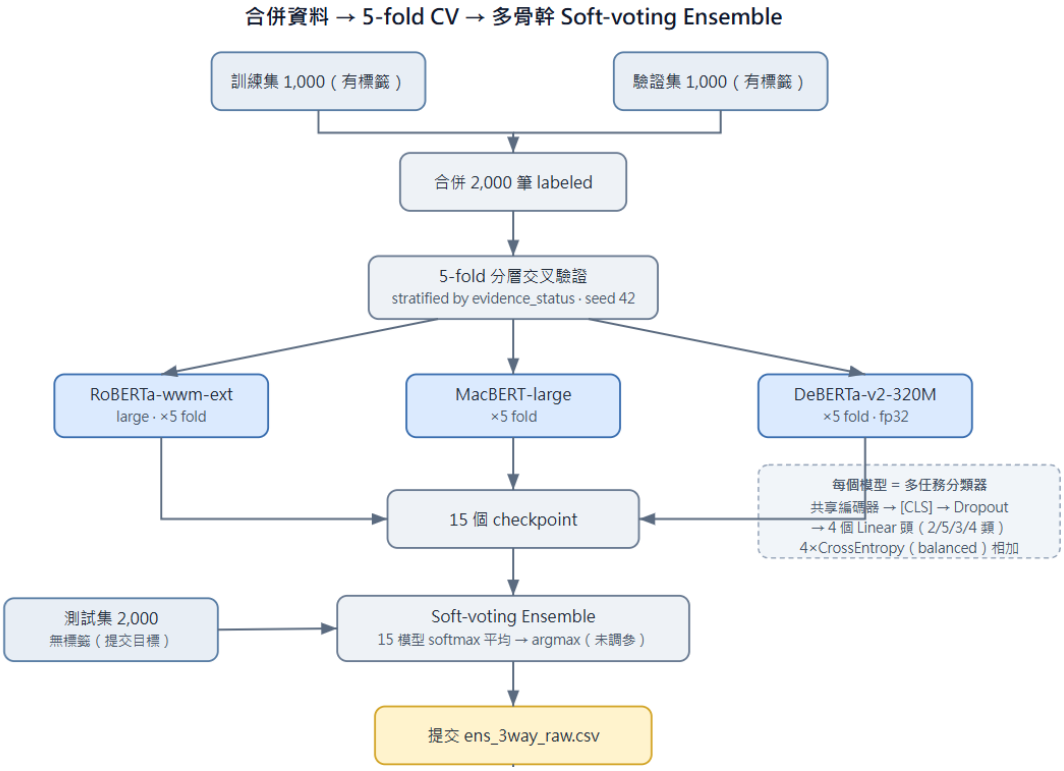
模型	來源 URL
chinese-roberta-wwm-ext-large	https://huggingface.co/hfl/chinese-roberta-wwm-ext-large

chinese-macbert-large	https://huggingface.co/hfl/chinese-macbert-large
Erlangshen-DeBERTa-v2-320M-Chinese	https://huggingface.co/IDEA-CCNL/Erlangshen-DeBERTa-v2-320M-Chinese

貳、演算方法與模型架構

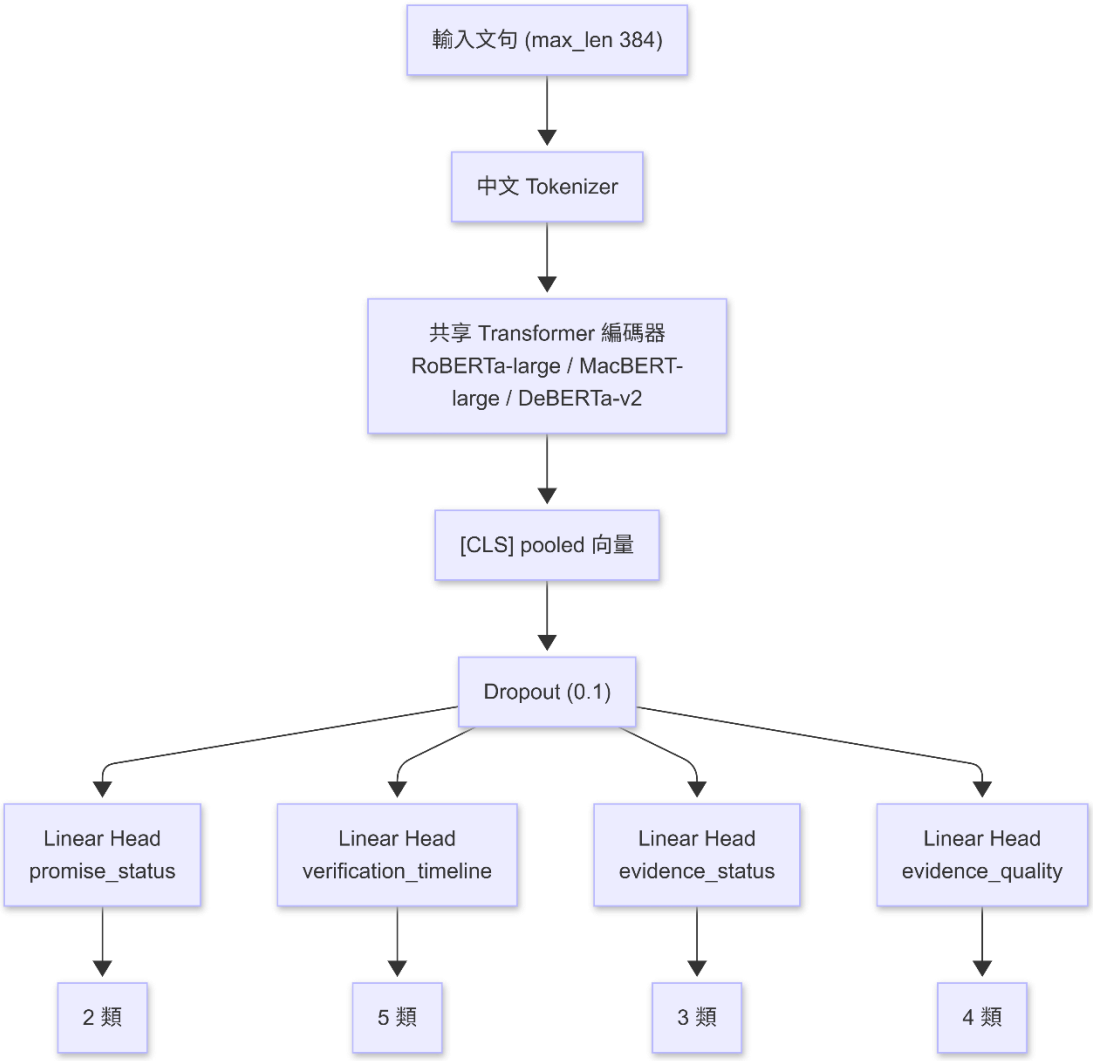
我們在本競賽用一個多任務 Transformer 分類器，並透過多骨幹模型的交叉驗證 ensemble 提升穩健度（圖一）。核心設計理念為以下三點：

1. 以共享編碼器及四個獨立分類頭同時學習四個相關子任務，讓任務間共享語意表徵。
2. 合併官方驗證集進訓練、改用 5-fold 交叉驗證評估，解決資料量不足與單一切分評估不穩的問題。
3. 三種中文預訓練骨幹（RoBERTa / MacBERT / DeBERTa）的 soft-voting ensemble，以模型多樣性換取泛化能力。



圖一：合併資料 → 5-fold CV → 多骨幹 Soft-voting Ensemble 流程圖

四個子任務共用同一個 Transformer 編碼器，使「承諾辨識、證據判斷、時間軸預測、證據品質評估」之間的語意關聯能被聯合學習。每個子任務各自有一個全連接層輸出類別分布。而損失函數為四個子任務的 CrossEntropyLoss 相加，每個任務都套用 balanced class weight（依各類別在訓練折中的出現頻率倒數加權），以對抗類別不平衡。



圖二：共享編碼器 + 四個獨立分類頭

Soft-voting：對 3 骨幹 × 5 fold 共 15 個 checkpoint，分別輸出每個子任務的 softmax 機率，取平均後 argmax 作為最終預測。平均在機率空間進行，使不同骨幹的信心度得以融合。最終提交檔 ens_3way_raw.csv 即為此 15-checkpoint 的純 ensemble 結果，未做任何後處理閾值調整（理由詳見陸章過擬合分析）。

另外我們針對以下兩個問題所採取的解決方法：

1. DeBERTa-v2 與 AMP fp16 不相容：訓練時出現 Attempting to unscale FP16 gradients，改為 fp32 訓練解決。
2. Erlangshen DeBERTa checkpoint 權重以 fp16 儲存：載入後編碼器輸出為 Half，與 fp32 分類頭衝突；於模型建立時對編碼器呼叫 .float() 強制轉 fp32 解決。

參、創新性

我們的創新並非單一新模型，而是在小型、極度不平衡資料集上的一套穩健決策方法論：

1. 以校正分析（calibration）驅動的反過擬合決策：
   我們建立「本地 OOF 分數 ↔ 實際 Leaderboard 分數」的對照，量化發現後處理閾值調整雖能灌水本地分數 +0.015，卻在測試集上反向衰退。據此主動棄用多數隊伍慣用的閾值後處理，改採未調參的純 ensemble。這種「不貪心」的反直覺決策，正是我們最具創新性的一點。

2. 小資料的穩健評估設計：
   合併官方驗證集使標註資料倍增（1,000 → 2,000），並以分層 5-fold 交叉驗證取代單一 hold-out，將原本受亂數種子影響高達 0.558–0.643 的評估雜訊，收斂為可信的折平均 ± 標準差。

3. 異質多骨幹 soft-voting：
   刻意選用架構互異的三種中文預訓練模型（RoBERTa / MacBERT / DeBERTa），即使較弱的骨幹（如 DeBERTa 單模 0.595）也能因犯錯方式不同而在投票中貢獻正向多樣性。

4. 對官方 baseline 的擴充：
   官方範例僅為「單一 hold-out、單模型」訓練腳本。本隊在其上新增 --merge-val（合併驗證集）、--cv-folds（交叉驗證）、--full-train（全量訓練）三項能力，並自行開發 predict_test.py（多 checkpoint soft-voting 推論）

與 tune_thresholds.py（OOF 閾值分析工具），形成完整的訓練—評估—推論管線。

肆、資料處理

資料集規模如下：

Dataset	數量	標籤
訓練集	1000	有
驗證集	1000	有
測試集	2000	無（提交結果）

類別分布如下：

子任務	類別	筆數	比例
promise_status	Yes	814	81.4%
	No	186	18.6%
verification_timeline	already	366	36.6%
	between_2_and_5	238	23.8%
	more_than_5	197	19.7%
	N/A	186	18.6%
	within_2	13	1.3%
evidence_status	Yes	677	67.7%
	N/A	186	18.6%
	No	137	13.7%
evidence_quality	Clear	552	55.2%
	N/A	323	32.3%
	Not Clear	124	12.4%
	Misleading	1	0.1%

文字長度的分析：最小長度：35 tokens；平均長度：208 tokens；最大長度：816 tokens；超過 256 tokens 的樣本：256 筆（25.6%）。

最後資料處理流程如下：

1. 標籤正規化：
   官方資料中部分欄位以空字串 "" 表示「不適用」，程式在載入時統一正規化為 N/A，並驗證每個欄位的值都落在合法類別集合內，避免標籤不一致。

2. 未做刪減或人為更正：
   保留全部 2,000 筆標註資料，未刪除或竄改任何標籤；對極稀少的 Misleading（僅 2 筆）採「保留 + class weight 加權」而非刪除。

3. 文字長度分析決定 max_len：
   訓練文句平均約 208 字，超過 256 字者不在少數，故將截斷長度設為 384（涵蓋絕大多數樣本）。

4. 合併驗證集：
   官方驗證集 1,000 筆同樣帶標籤，併入訓練後得到 2,000 筆標註資料，直接倍增資料量。

5. 類別不平衡處理：
   各子任務皆有嚴重不平衡，以 balanced class weight（頻率倒數加權）於損失函數中補償，而非重採樣。

6. 5-fold 交叉驗證：
   以 evidence_status 做分層切分（種子 42）。改用 CV 的動機是早期單一 hold-out 在不同種子下分數落差極大（0.558 – 0.643），無法可靠判斷改動是否真有效。

伍、訓練方式

我們的訓練流程如下：

1. 載入預訓練權重（RoBERTa-large / MacBERT-large / DeBERTa-v2-320M）
2. 建構多任務分類器（共享編碼器 + 4 個 Linear Head）
3. 對每個 fold 訓練（4/5 train, 1/5 valid）

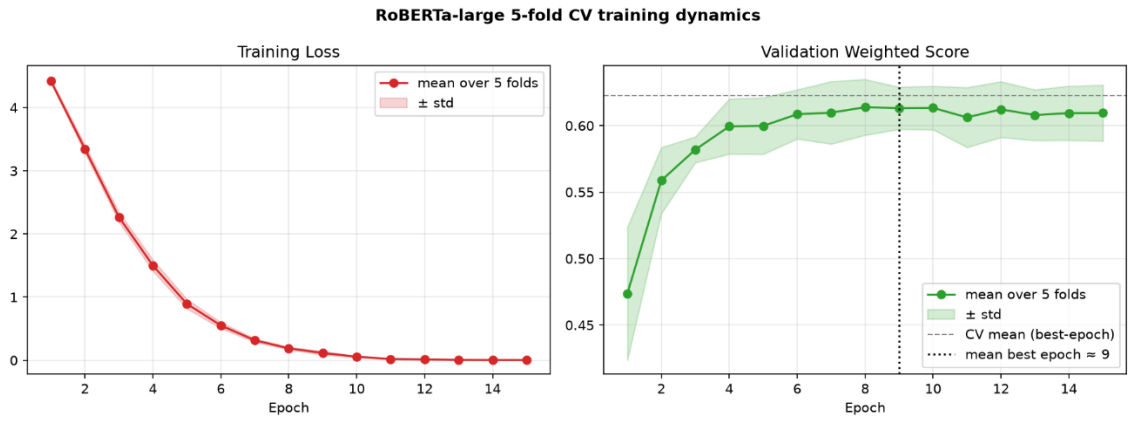
4. 每個 epoch 計算驗證加權分數，保存最佳 checkpoint

5. 共 5 folds × 3 骨幹 = 15 個 checkpoint

各模型訓練設定：

項目	RoBERTa-large	MacBERT-large	DeBERTa-v2-320M
batch_size	16	16	8
學習率	4e-5	4e-5	2e-5
epochs	15	15	15
max_len	384	384	384
fp16	✓	✓	✕ (fp32)
最佳 epoch	6~12	6~12	6~12

參數	數值
損失函數	4 × CrossEntropyLoss（balanced class weight）相加
Optimizer	AdamW, weight_decay=0.01, warmup_ratio=0.1, grad_clip=1.0
亂數種子	42



圖三：RoBERTa-large 5-fold 訓練曲線。

左圖訓練損失平滑且單調收斂至接近 0，代表模型確實在學習、無發散；右圖驗證加權分數上升後於第 6–9 epoch 達高原（黑色虛線為平均最佳 epoch）而非崩跌，顯示無嚴重過擬合。我們取「驗證最佳 epoch」的 checkpoint，作為兼顧收斂與泛化的訓練過程佐證。

訓練時長：總計約 10.75 小時（15 個 checkpoint），推論（15 模型 soft-voting）：約 10～15 分鐘。

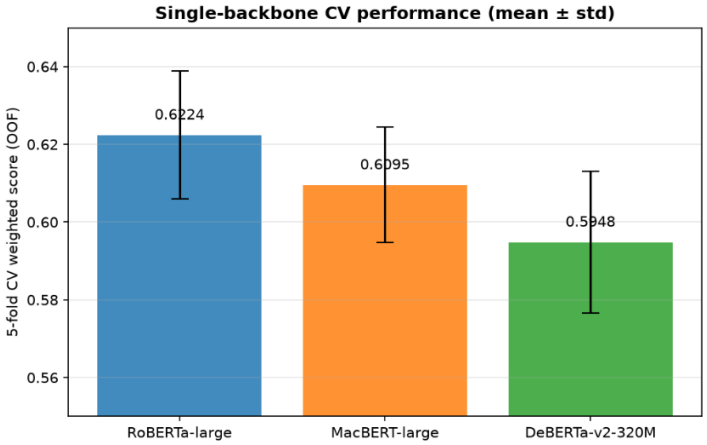
模型	每 fold	5-fold 合計
RoBERTa-large	~ 21 min	~ 106 min
MacBERT-large	~ 21 min	~ 105 min
DeBERTa-v2-320M	~ 87 min	~ 434 min

陸、分析與結論

各骨幹 5-fold CV 結果：

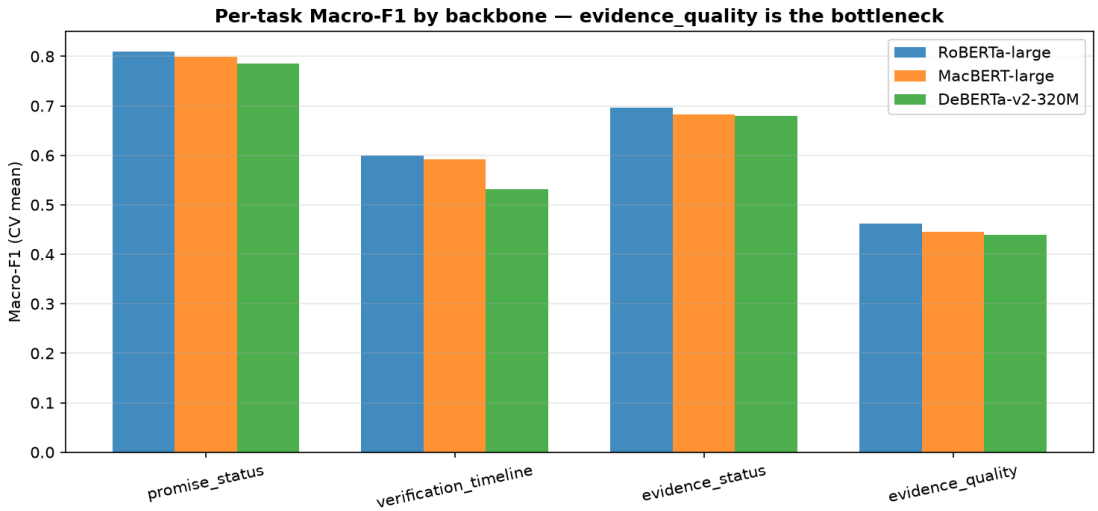
模型	加權分數	promise	timeline	ev_status	ev_quality
RoBERTa-large	0.6224 ± 0.0165	0.809	0.599	0.697	0.462
MacBERT-large	0.6095 ± 0.0149	0.800	0.592	0.683	0.445
DeBERTa-v2-320M	0.5948 ± 0.0182	0.785	0.532	0.680	0.440

RoBERTa-large 在各項子任務上皆領先，尤其 verification_timeline 領先 DeBERTa 達 0.067，反映 RoBERTa 對時間語意的理解能力較佳。但三者差距不大（總分極差 僅 0.0276），且標準差互有重疊，故不應只選 RoBERTa 單模，而是將三者皆納入 ensemble 以利用其多樣性。由圖四可觀察：RoBERTa-large 為單模最強（0.6224 ± 0.0165），MacBERT 與 DeBERTa 雖較弱但標準差區間與 RoBERTa 部分重疊，三者在不同折各有勝負，反映模型多樣性足以貢獻 ensemble。



圖四：各骨幹 CV 加權分數

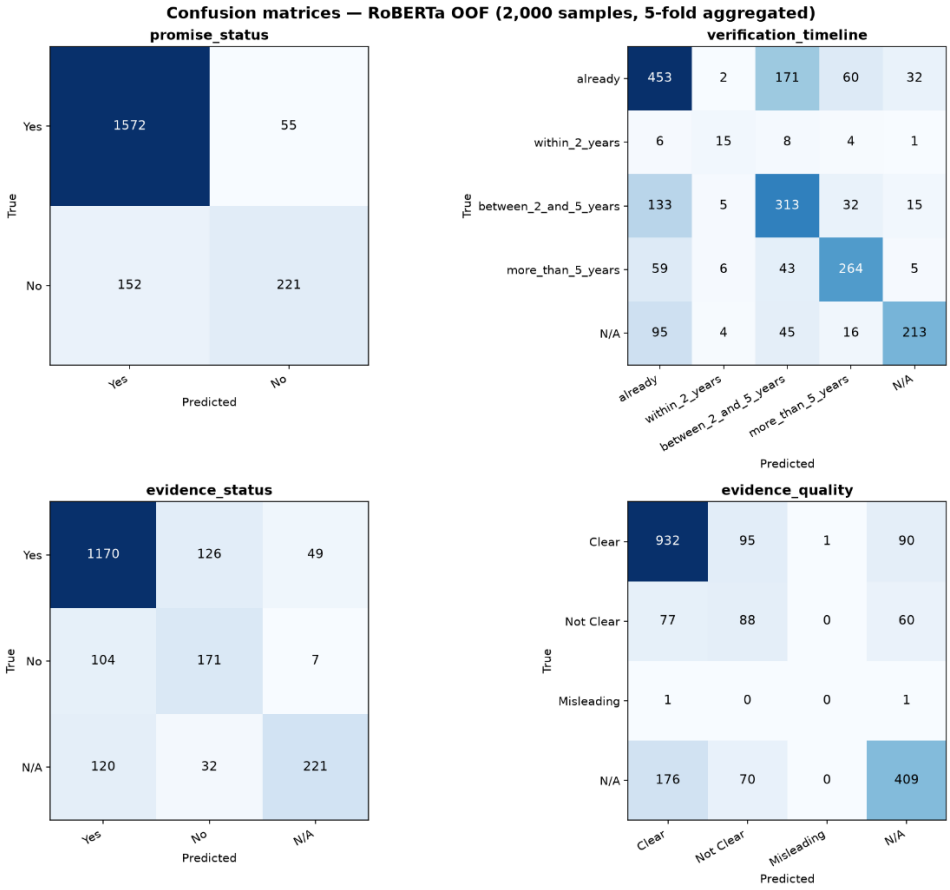
圖五中我們可以看到三個骨幹在各任務上的 Macro-F1 趨勢完全一致——promise_status 最高（0.785 – 0.809）、evidence_status 次之（0.680 – 0.697）、verification_timeline 再次（0.532 – 0.599）、evidence_quality 最低且明顯低落（0.440 – 0.462）。這說明任務難度排序是資料本身的特性，與模型架構無關；而 evidence_quality 做為權重最高（35%）的項目同時也是最弱的一環，是整體分數的天花板。



圖五：逐任務 Macro-F1 對照

各任務錯誤型態：

- promise_status（最佳）：少數類 No 被誤判為 Yes（recall 偏低）。
- verification_timeline：混淆集中在 already / between_2_and_5 / more_than_5 三者；within_2_years 因樣本極少幾乎無法辨識。
- evidence_status：三類大致可分，少量 Yes 與 No/N/A 互混。
- evidence_quality（瓶頸）：Clear 良好；Not Clear 常誤判為 Clear 或 N/A；Misleading 因樣本極稀少而全數預測錯誤。



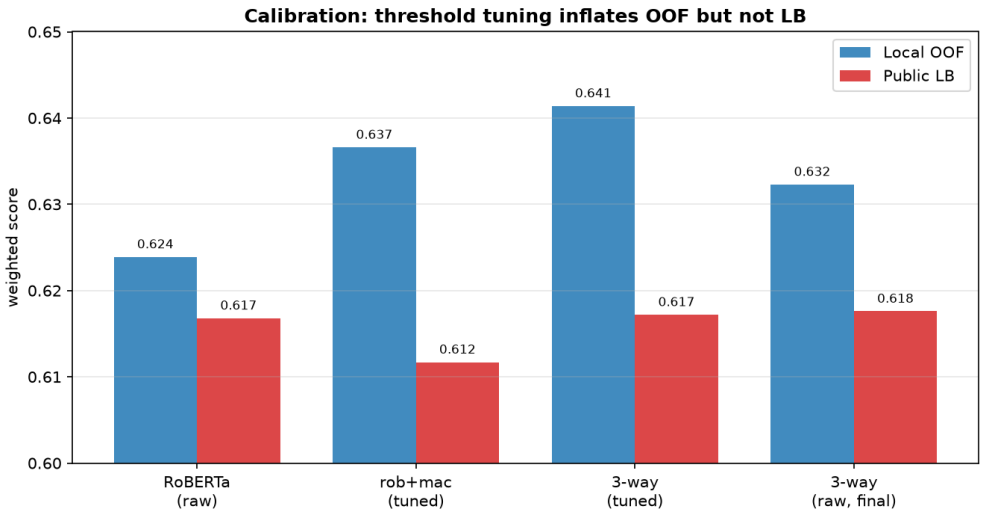
圖六：四任務混淆矩陣

我們曾實作 per-class 決策閾值調整（threshold tuning）：在交叉驗證的 out-of-fold 預測上，以座標上升法搜尋每個類別的機率偏置以最大化 Macro-F1。此法在本地 OOF 上看似帶來 +0.01～0.015 的提升。但當我們提交測試集後發現，經調參的版本反而表現較差：

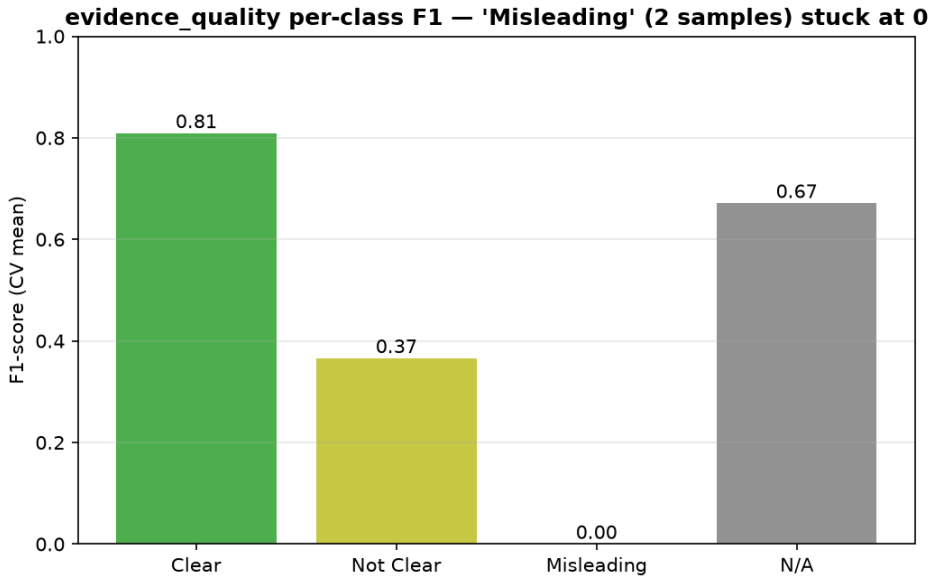
提交版本	本地 OOF	Public LB	落差
RoBERTa ensemble（未調參）	0.6239	0.6168	−0.007
roberta+macbert（已調參）	0.6366	0.6117	−0.025
3-way（已調參）	0.6414	0.6172	−0.024
3-way（未調參，最終）	0.6323	0.6176	−0.015

調參版本（圖七中間兩組）在 OOF 上最高，實際 LB 卻最低，清楚顯示閾值調整的過擬合；未調參版本（左、右）落差最小。Misleading 因全資料僅 2 筆而恆為 0，是 4 類 Macro-F1 被壓低的主因。evidence_quality（權重最高 35%）為本

任務瓶頸，其 Macro-F1 約僅 0.44，主因是 Misleading 類別樣本數極少（4 類 Macro-F1 因此被天然壓在約 0.75 上限），標準監督式學習難以突破。



圖七：OOF 與 Leaderboard 校正對照



圖八：evidence_quality 逐類別 F1

結論：以「合併資料 + 交叉驗證 + 多骨幹 soft-voting ensemble」為主軸，透過誠實的 OOF ↔ LB 校正分析，辨識並避開閾值調整的過擬合陷阱，最終以未調參的 3-骨幹 ensemble 取得所有參賽隊伍中的第 1 名（0.6538186）。其中最大的方法論收穫是：在小型資料集上，可信的離線驗證指標（raw argmax CV）比追求帳面分數的後處理更重要。

柒、程式碼

GitHub Repository: https://github.com/whyhugo/VeriPromiseESG

檔案	功能
scripts/train_baseline.py	多任務訓練主程式 （支援 --merge-val, --cv-folds, --full-train）
scripts/predict_test.py	多 checkpoint soft-voting 推論，輸出 CSV
scripts/tune_thresholds.py	OOF 閾值調整工具（最終未採用）
scripts/run_lastday.sh	訓練流程腳本
scripts/run_deberta_3way.sh	3-way ensemble 腳本
scripts/make_final_submission.sh	最終提交流程腳本
requirements.txt	Python 依賴套件
README.md	環境安裝與使用說明

捌、使用的外部資源與參考文獻

預訓練模型（詳見第壹章）

模型	來源	用途
hfl/chinese-roberta-wwm-ext-large	HFL （哈工大訊飛聯合實驗室）	分類骨幹
hfl/chinese-macbert-large	HFL （哈工大訊飛聯合實驗室）	分類骨幹
IDEA-CCNL/Erlangshen-DeBERTa-v2-320M-Chinese	IDEA-CCNL （封神榜）	分類骨幹

使用之開源函式庫：PyTorch、HuggingFace Transformers、scikit-learn、TensorBoard、NumPy、pandas。

生成式 AI 使用聲明：

- 工具與版本：Claude Code（Anthropic Claude，使用模型 claude-sonnet-4-6 與 claude-opus-4-8）。

- 具體使用方法：作為程式開發與分析的輔助工具，協助項目包括——撰寫／重構訓練與推論程式碼、設計交叉驗證與 ensemble 方法、除錯（如上述 DeBERTa fp16 相容性問題）、以及對實驗結果的分析與解讀（如辨識出閾值調整的過擬合現象）。
- 未使用之項目：未使用任何生成式 AI 進行資料擴增、合成標籤（soft label）或特徵生成；所有模型訓練僅依賴競賽官方提供之標註資料。（本隊曾評估以 LLM 為 Misleading 類別產生 soft label，但最終並未實作採用。）
- 貢獻比例聲明：競賽策略方向、所有實驗之執行、模型與提交決策、最終結果判讀，皆由隊伍主導與決定；生成式 AI 僅作為程式撰寫與分析之輔助。

參考文獻：

1. Cui, Y., Che, W., Liu, T., Qin, B., & Yang, Z. (2021). Pre-training with whole word masking for Chinese BERT. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 29, 3504–3514. https://doi.org/10.1109/TASLP.2021.3124365
2. Cui, Y., Che, W., Liu, T., Qin, B., Wang, S., & Hu, G. (2020). Revisiting pre-trained models for Chinese natural language processing. In Findings of the Association for Computational Linguistics: EMNLP 2020 (pp. 657–668). https://doi.org/10.18653/v1/2020.findings-emnlp.58
3. He, P., Liu, X., Gao, J., & Chen, W. (2021). DeBERTa: Decoding-enhanced BERT with disentangled attention. In International Conference on Learning Representations. https://openreview.net/forum?id=XPZIaotutsD
4. Wang, J., Zhang, Y., Zhang, L., Yang, Y., Gao, Z., Wu, Z., … & Zhang, Z. (2022). Fengshenbang 1.0: Being the foundation of Chinese cognitive intelligence [Preprint]. arXiv. https://arxiv.org/abs/2209.02970
5. Paszke, A., Gross, S., Massa, F., Lerer, A., Bradbury, J., Chanan, G., Killeen, T., Lin, Z., Gimelshein, N., Antiga, L., Desmaison, A., Köpf, A., Yang, E., DeVito, Z., Raison, M., Tejani, A., Chilamkurthy, S., Steiner, B., Fang, L., … Chintala, S. (2019). PyTorch: An imperative style, high-performance deep learning library. In Advances in Neural Information Processing Systems 32 (pp. 8024–8035).

https://papers.nips.cc/paper/9015-pytorch-an-imperative-style-high-performance-deep-learning-library

6. Wolf, T., Debut, L., Sanh, V., Chaumond, J., Delangue, C., Moi, A., Cistac, P., Rault, T., Louf, R., Funtowicz, M., Davison, J., Shleifer, S., von Platen, P., Ma, C., Jernite, Y., Plu, J., Xu, C., Scao, T. L., Gugger, S., … Rush, A. M. (2020). Transformers: State-of-the-art natural language processing. In Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations (pp. 38–45). https://doi.org/10.18653/v1/2020.emnlp-demos.6
7. Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. Journal of Machine Learning Research, 12, 2825–2830. https://www.jmlr.org/papers/v12/pedregosa11a.html
8. Anthropic. (2026). Claude Code [Large language model]. https://www.anthropic.com

作者聯絡資料表

隊伍名稱	TEAM_10671	Private Leaderboard 成績	0.6538186	Private Leaderboard 名次	1
隊長	鄭兆宏 Chao-Hung, Cheng	國立臺灣師範大學資訊工程學系	National Taiwan Normal University Department of Computer Science and Information Engineering	0908-153-861	41247008s@gapps.ntnu.edu.tw
隊員1	王修佑 Hugo Hsiuyu, Wang	國立臺灣師範大學資訊工程學系	National Taiwan Normal University Department of Computer Science and Information Engineering	0919-987-808	hugo.tw.wang@gmail.com
隊員2	林德恩 De-En, Lin	國立臺灣師範大學資訊工程學系	National Taiwan Normal University Department of Computer Science and Information Engineering	0900-603-451	darrin.de88@gmail.com
隊員3	韓欣劭 Xin-Shao, Hon	國立臺灣師範大學資訊工程學系	National Taiwan Normal University Department of Computer Science and Information Engineering	0966-880-878	baboom003@gmail.com